실제 OpenAI 호출 · 합성 가입 요청 · 각 역할 1회

실제 AI Agent 통신 검증
호출 성공과 내용 정확성을 구분한 결과

저장된 실제 API 응답을 기준으로 송수신·계약 일치·시간을 정리했습니다.
이번 보고서 작성에서는 모델을 추가 호출하지 않았습니다.

측정 2026.11.08 19:20:12–19:20:37 KST · 전체 수집 경과 25.175초

OpenAI API 응답
5/5
모든 호출 HTTP 200
인증·요청 처리 정상

A2A 송수신 데이터
5/5
원본·실행기·완료 결과 일치
Message·Task·Context 대조

구조화된 계약 내용
4/5
멀티 4역할 통과
싱글 의존 관계 불일치 1결과

사용자가 확인하고자 한 세 영역

영역	관측한 결과
송신·수신 정확성	5개 결과에서 전송 경계와 식별자 대조 통과. 관측된 전달 누락·변형 없음.
내용 오류·할루시네이션	싱글의 의존 관계 표현 불일치 탐지. 자유 서술 전체의 사실성과 일반적인 오류율은 미검증.
속도 차이	역할별 실제 API 왕복 3.510–8.889초. 각 1회이며 출력 분량과 작업 구성이 다름.

실행 조건

항목	조건
모델	gpt-4.1-mini-2025-04-14 / 실제 응답 모델도 모두 동일
설정	temperature=0 · 역할당 최대 출력 8,192토큰 · 호출 시간 설정 60초
요청 자료	합성 가입 요청 1개 / 요구사항 14개 · 합격 기준 18개 · 권한 규칙 5개 · 미결정 질문 2개
호출 범위	멀티 4회 + 싱글 1회 / 최대 5회 / 자동 재시도·모델 대체 없음

판정: 실제 호출과 송수신은 정상입니다. 싱글의 계약 불일치로 전체 상태는 **FAIL_OR_INCOMPLETE**입니다. HTTP 200이나 Task COMPLETED를 내용 정확성 또는 제품 성공으로 간주하지 않습니다.

01 / 송신 값과 수신 값을 각각 기록해 비교

모델까지 가는 입력과 돌아오는 결과는 보존됐습니다.

진단 함수끼리 직접 값을 넘긴 실험이 아닙니다. 실제 프로젝트의 A2A 클라이언트·인증된 Agent 서버·Task 저장소·Artifact 조회를 사용했습니다.

멀티 경로

Orchestrator → Planner → Orchestrator → Developer → Orchestrator → QA·Security 병렬

싱글 경로

Orchestrator → 별도 SINGLE_AGENT 서버 → 네 역할 계약을 포함한 응답

역할 실행기에서 실제 OpenAI Responses API를 호출하고, 결과를 A2A Artifact로 반환했습니다.

역할별 실제 전송 대조

대상	A2A 본문 B	원본→실행기	생성→수신 결과	식별자	API 입력
Planner	12897	PASS	PASS	PASS	PASS
Developer	14810	PASS	PASS	PASS	PASS
QA	14764	PASS	PASS	PASS	PASS
Security	14764	PASS	PASS	PASS	PASS
Single	12897	PASS	PASS	PASS	PASS

API 입력은 실제 HTTP 요청의 input 해시와 모델 호출 직전 입력 해시를 대조했습니다. A2A 본문 바이트 수와 OpenAI API 입력 토큰 수는 다른 단위입니다. OpenAI 내부의 수신·추론 과정은 직접 관측하지 않았습니다.

요청 경계

원본 → 직렬화 → 서버 본문 → 파서 접수 → 실행기 입력을 따로 기록했습니다.

결과 경계

실행기가 생성한 결과와 Orchestrator가 조회한 완료 Artifact를 비교했습니다.

식별자·메타데이터

수신측 Message·Task·Context ID와 송신·응답 값을 대조했습니다. 메타데이터 대조도 모두 통과했습니다.

비교 기준

JSON 값·타입·배열 순서를 비교합니다. 공백·키 순서는 제외하며 Struct의 100.0과 JSON의 100은 같은 숫자로 취급합니다.

누가 어떤 값을 만들었는가

주체	생성·확인한 항목
실제 모델	숫자·라벨·요구사항 개수, 요구사항 범위·정책·권한·미결정 사항·역할별 계약
호스트 전송 계층	Probe ID, 요청 fingerprint, 이전 결과 hash, 실제 수신 ID, API 입력 해시
호스트 검증기	Agent 입력 밖의 고정 참조와 모델의 구조화된 주장 대조

이번 결과에서 확인한 것

모델이 잘못 작성한 싱글 응답도 생성 후 수신까지 그대로 전달됐습니다. 전송 실패와 내용 불일치를 구분할 수 있었습니다. 이 5건만으로 모든 운영 환경의 무손실을 보증하지 않습니다.

02 / API 호출 성공 후에도 발견한 실제 내용 문제

싱글이 의존 관계를 요구한 연결 쌍으로 작성하지 못했습니다.

문제 위치: `roleContract.roles.PLANNER.dependencyEdges`

요청은 각 의존 관계를 [의존 ID, 현재 요구사항 ID]로 표현하도록 했습니다.

고정 참조 / 17개 연결 쌍

각 관계의 양 끝을 함께 기록

```
[
  [
    "REQ-SU-01",
    "REQ-SU-02"
  ],
  [
    "REQ-SU-02",
    "REQ-SU-03"
  ]
]
```

실제 싱글 응답 / 14개 묶음

요구사항별 의존 ID 목록으로 작성

```
[
  [],
  [
    "REQ-SU-01"
  ]
]
```

각각 앞 2개만 표시했습니다. 전체 원본과 23개 세부 차이 항목은 report.json에 있습니다. '17과 14의 차이'는 요청 3건이 전송 중 사라졌다는 의미가 아닙니다.

형식 검사와 계약 검사가 달랐던 이유

검사 층	이번 싱글 결과	해석
JSON·Schema	PASS	배열 안에 문자열 배열이 있다는 필드·타입 구조에는 부합
송수신·ID	PASS	모델 결과가 전달 도중 바뀐 현상은 관측되지 않음
고정 계약	FAIL	요구한 17개 명시적 연결 쌍과 일치하지 않음
자유 서술 전체	미검증	설명 문장 전체의 사실성을 자동 판정한 것은 아님

발견 사항의 해석

이 결과는 모델의 구조화된 계약 불일치입니다. 단 한 번의 싱글 응답으로 모든 싱글이 잘못된다거나 일반적인 할루시네이션 비율이 20%라고 결론 내릴 수 없습니다.

후속 보완 제안 — 이번 실행에서 적용·재호출하지 않음

- 각 의존 관계가 정확히 두 ID를 가진다는 구조를 Schema나 명시적인 객체 필드로 더 분명히 표현합니다.
- 싱글 지시에서 '요구사항별 묶음'과 '의존 관계별 연결 쌍'을 구분하도록 설명을 보완합니다.
- 형식을 맞춰도 관계가 빠질 수 있으므로, 원본의 모든 관계를 대조하는 고정 계약 검사를 유지합니다.
- 별도 호출 예산으로 반복 측정하고, 이번 실패 원본과 수정 후 결과를 구분해 보관합니다.

03 / 목업의 ms 값과 실제 모델의 초 단위를 구분

실제 API 왕복은 3.510–8.889초, 역할별 출력 분량도 달랐습니다.

각 역할 1회입니다. 아래 시간은 평균·중앙값·p95가 아닌 이번 실측값이며, 토큰은 API가 반환한 실제 사용량입니다.

역할	API 왕복 s	Agent 구간 s	요청 전체 s	입력 토큰	출력 토큰	합계 토큰
Planner	5.366	5.379	5.500	4,222	574	4,796
Developer	3.510	3.525	3.642	4,970	437	5,407
QA	6.148	6.180	6.377	5,386	951	6,337
Security	3.807	3.839	3.999	4,809	425	5,234
Single	8.889	8.916	9.034	5,067	1,280	6,347

입력 토큰

24,454

요청 문서·역할 지시·Schema·이전 결과 등 API 입력

출력 토큰

3,667

실제 모델이 반환한 출력
역할마다 분량이 다름

총 사용 토큰

28,121

실제 사용량 합계
청구 금액을 계산한 값은 아님

API 왕복

프로바이더 요청 직전부터 응답 파싱·검증까지입니다. 네트워크·서비스 처리·전체 출력 수신을 포함하며 순수 모델 계산시간은 아닙니다.

Agent 구간

Agent 실행기 입력 관측부터 결과 객체 준비까지입니다. API 호출 외의 계측·데이터 처리·스케줄링도 포함합니다.

요청 전체

Orchestrator 준비부터 완료 결과 관측까지입니다. Card 조회·전송·실행 대기·결과 저장·폴링 등도 포함합니다.

속도 차이의 의미

출력 분량·역할 지시·네트워크가 달라 처리시간도 다를 수 있습니다. 이번 표본에서 속도 차이에 따른 데이터 누락은 관측되지 않았습니다.

실행 단위 경과시간

실행	이번 경과시간	해석
멀티 4역할	15.537초	Planner·Developer 순차, QA·Security 병렬
싱글 1역할	9.040초	한 응답에 네 역할 계약 포함 / 계약 불일치 존재

Single/Multi 성능 우열을 판단하는 비교 실험은 아닙니다.
소표본이고 결과 품질도 같지 않습니다. 병렬 구간의 시간을 합산해 전체 경과시간으로 만들지 않습니다. 동시 대량 요청·원격 배포·장기 부하 및 계측 부담의 영향은 별도로 확인해야 합니다.

04 / 확인한 범위와 남은 검증을 구분

실제 호출은 확인했고, 제품 완성도 검증은 남아 있습니다.

항목	이번 근거와 한계
실제 OpenAI 연결	5회 실제 HTTP 200. 선택 모델과 응답 모델 일치. API 입력 해시 대조 통과.
Agent 통신	실제 로컬 A2A·인증·임시 SQLite·Artifact 조회. 5개 결과의 전송 경계 대조 통과.
모델 내용 검사	고정된 합성 계약에서 4개 일치·싱글 1개 불일치. 자유 서술 전체는 미검증.
코드 회귀 검사	31개 통과 / 13.261초. 이 검사는 가짜 API 응답을 사용해 추가 과금 없이 수행.
결과 화면	Chrome에서 역할 5개·요약·싱글 차이 확인. 320/390px 가로 넘침과 실행 오류 없음.
미수행	제품용 코드 생성·MCP·Docker·빌드·실제 QA·보안 스캔·배포·동시 부하.

남은 작업의 우선순위

1. 싱글 의존 관계의 출력 구조·지시를 보완하고, 원본 전체 관계 대조를 유지합니다.
2. 별도 예산으로 정상·미결정·복잡한 요청을 반복해 재현성과 내용 정확성을 확인합니다.
3. 관측 코드 부담·완료 확인 비용과 실제 모델 시간을 분리하고, 요청이 쌓이는 상황을 검증합니다.
4. 제품용 실행기·도구 실행 근거와 연결한 뒤 개발·QA·보안 결과의 사실성을 확인합니다.

같은 폴더의 원본·보고서

`report.json` — 실제 호출 5회·모든 관측값·모델 결과·불일치·시간·토큰

`verification.json` — 회귀·화면·키 비노출 검사와 당시 파일 해시

`report.html` — 기존 결과 탐색 화면 / `report-print.html` — 이 보고서 인쇄 원본

`report.pdf` — 공유용 PDF / `pdf-verification.json` — PDF 형식·무결성 점검

실제 호출 원본 report.json SHA-256

`4c2dc3b29b81748b408c87f6840f2ed096f927fe856966c73a3e4299f0b5d5ad`

기존 검증 기록 verification.json SHA-256

`467e82bd4bb2fa36a2ae1812266297c07717ed160982557581f6aced4efce093`

이번 보고서는 저장된 실제 결과로만 작성했습니다. 추가 유료 호출 0회, 자동 재시도 0회이며, 발견한 싱글 결과를 정답으로 교체하지 않았습니다. **연결 성공·진단 Task 완료·제품 성공은 서로 다른 판정**입니다.

입력은 합성 가입 자료입니다. 루트 .env의 키는 인증에 사용했으며 모델 입력·결과·보고서에는 포함하지 않았습니다. 출력 Schema는 자료의 필드·타입을 제한하지만 enum·const로 정답 값을 강제하지 않습니다. 해시·UUID는 호스트가 생성한 전송 증거입니다.