RESULT AT A GLANCE

전달은 모두 정상.
싱글의 결과 작성에는 오류 1건.

실제 OpenAI를 호출해 요청과 결과가 그대로 오가는지 확인했습니다.
통신 성공과 AI가 작성한 내용의 정확성을 구분해 정리했습니다.

실제 API 호출	요청 · 결과 송수신	정해진 내용 기준 충족
5 / 5	**5 / 5**	**4 / 5**
모두 정상 응답 HTTP 200	보낸 내용과 받은 내용 일치 관측된 누락·변형 없음	멀티 4역할 충족 싱글 출력 불일치

01 **제대로 받았나**

이번 5건은 요청과 응답이 모두 그대로 전달됐습니다.
“100을 보냈는데 90만 받는 문제”는 발견되지 않았습니다.

02 **할루시네이션**

싱글이 작업 연결 관계를 요청한 방식과 다르게 작성했습니다.
전달 오류와 별개로, AI 답변의 지시 준수 오류가 있었습니다.

03 **속도 차이**

API 응답은 역할에 따라 약 3.51~8.89초였습니다.
멀티 안의 가장 빠른 역할과 느린 역할은 약 2.64초 차이입니다.

지금 가장 먼저 손볼 부분

싱글이 “어떤 작업이 끝나야 다음 작업을 시작하는지”를
정확한 연결 쌍으로 작성하도록 출력 규칙을 보완해야 합니다.

이번 검사의 범위

준비된 회원가입 요구사항을 실제 AI가 읽고, 역할별 정리 결과를 A2A로 주고받는 진단입니다. 실제 코드 생성·빌드·제품 QA·보안 스캔까지 완료한 검사는 아닙니다.

실측: 2026년 11월 8일 19:20:12~19:20:37 KST · 멀티 4회 + 싱글 1회
모델: gpt-4.1-mini-2025-04-14 · temperature 0 · 자동 재시도 없음

01-02 / DELIVERY & CONTENT

잘 전달됐는지와 답변이 맞는지는 따로 확인했습니다.

멀티 4역할과 싱글 1개, 총 5건의 송수신을 대조했습니다.
누가 받았는지 식별자도 확인하고, 결과의 주요 내용도 원본과 비교했습니다.

역할	요청 전달	결과 전달	정해진 내용 대조
기획	일치	일치	기준 충족
개발	일치	일치	기준 충족
QA · 품질	일치	일치	기준 충족
보안	일치	일치	기준 충족
싱글 · 네 역할 통합	일치	일치	연결 관계 오류

송수신 대조는 요청 생성·전송·수신·실행기 입력과 결과 반환을 확인한 것입니다.
AI가 요청의 모든 의미를 이해했다는 보장은 아닙니다.

싱글에서 발견한 오류를 쉽게 설명하면

"A 작업이 끝나야 B 작업을 시작한다"는 관계를 **연결마다 두 ID의 쌍**으로 작성하라고 요청했습니다. 싱글은 이를 요구사항별 목록으로 다르게 정리했습니다.

요청한 결과

연결 쌍 17개

각 관계를 [먼저 할 작업 ID, 다음 작업 ID]로 작성

실제 싱글의 결과

목록 묶음 14개

빈 목록·ID가 하나인 목록도 포함해, 요청한 표현과 불일치

> **17개 중 3개가 전송 도중 사라졌다는 뜻이 아닙니다.**
> AI가 결과의 정리 방식을 잘못 작성했고, 그 잘못된 답변도 전달 자체는 그대로 이루어졌습니다.

할루시네이션에 대해 말할 수 있는 범위

이번에 확인된 것은 **출력 규칙·지시를 지키지 못한 오류**입니다. 이를 허위 사실 생성이라고 단정하거나, 할루시네이션 비율이 20%라고 계산할 수는 없습니다.

정해둔 정책·권한·의존 관계 등은 원본과 대조했지만, **자유롭게 작성한 모든 설명 문장의 사실성은 미검증**입니다.

문제 위치: `roleContract.roles.PLANNER.dependencyEdges`
기본 JSON 형식 검사에는 통과했고, 별도의 내용 대조 검사에서 불일치를 발견했습니다.

03 / SPEED

요청을 넘기는 시간과 AI 답변을 기다리는 시간을 나눴습니다.

멀티 역할 간 API 응답 시간은 약 2.64초, 약 1.75배 차이가 났습니다.
싱글은 네 역할의 결과를 한 번에 작성하므로 별도로 해석해야 합니다.

역할	요청 전달[1]	API 응답[2]	출력 토큰[3]
기획	1.18 ms	**5.366초**	574
개발	1.58 ms	**3.510초**	437
QA · 품질	5.47 ms	**6.148초**	951
보안	35.74 ms	**3.807초**	425
싱글 · 네 역할 통합	1.09 ms	**8.889초**	1,280

[1] 같은 컴퓨터 안에서 요청이 Agent 수신 지점까지 도달하는 구간입니다.
[2] OpenAI 요청부터 응답 파싱·검증까지로, 네트워크와 서비스 처리·답변 생성을 포함합니다.
[3] 답변 분량을 나타내는 단위입니다. 많을수록 시간이 늘 수 있지만, 단독 원인으로 단정하지 않습니다.
1,000 ms = 1초입니다. 두 시간 열은 측정 구간이 달라 직접 비교하는 성능 순위가 아닙니다.

이번 실행에서 시간을 많이 쓴 구간

로컬 요청 전달은 약 **0.001~0.036초**, API 응답은 약 **3.51~8.89초**였습니다. 이번 측정에서는 요청을 넘기는 시간보다 AI 답변을 기다리는 구간이 길었습니다.

속도 차이 때문에 데이터가 빠진 증거는 없었습니다.

역할별 작업과 답변 분량이 달라 시간 차이가 날 수 있습니다. 이번에는 송수신 대조가 모두 통과했습니다. 다만 동시 요청이 쌓일 때의 대기·누락·중복은 별도로 검증해야 합니다.

전체 진행 시간도 기록했지만, 우열을 정할 수는 없습니다.

멀티 4역할 합동 실행

15.537초

기획 → 개발 → QA·보안 병렬
API 호출 4회

싱글 한 번의 실행

9.040초

네 역할의 정리 결과를 한 응답에 포함
API 호출 1회 · 내용 불일치 있음

각 역할 표본이 1개뿐이고 출력 구성·정확성이 다릅니다. 이 결과로 싱글이 더 우수하다거나 멀티가 느리다고 일반화할 수 없습니다. 순수 모델 계산 시간이나 운영 네트워크 성능을 분리한 실험도 아닙니다.

04 / ISSUES & NEXT STEPS

확인된 오류 1개와 검증이 더 필요한 부분을 구분했습니다.

1 싱글의 연결 관계 출력 규칙 보완 · 확인된 오류

모델이 요청한 연결 쌍 표현을 지키지 않았습니다. 기본 JSON 형식 검사는 이를 허용했지만, 별도의 내용 대조 검사가 오류를 잡았습니다.

다음 조치: 각 관계를 “먼저 할 작업 / 다음 작업” 두 필드로 더 명확히 정의하거나, 두 ID 쌍이라는 조건을 강화합니다. 지시문도 보완하고 전체 연결 관계 대조를 유지한 채 재검증합니다.

2 반복 실행과 동시 요청 확인 · 아직 미검증

역할마다 한 번만 실행해, 반복해도 같은 품질인지와 요청이 몰릴 때의 동작은 아직 판단할 수 없습니다.

다음 조치: 같은 조건으로 반복 측정하고, 느린 Agent를 기다리는 동안 요청 누락·중복·다른 작업 결과의 혼입이 없는지 확인합니다. 평균·중앙값·느린 경우의 시간을 함께 봅니다.

3 제품의 실제 개발 흐름 검증 · 이번 실험 범위 밖

이번에는 진단용 실행기로 요구사항을 읽고 정리 결과를 전달했습니다. 제품용 오케스트레이터의 전체 개발 흐름을 완료한 실험은 아닙니다.

다음 조치: 제품용 오케스트레이터 → 코드 생성 → 빌드 → QA → 보안 검사까지 연결해, 같은 코드 버전과 결과물이 전달되는지 확인합니다.

이번 결과로 보고할 수 있는 내용

실제 OpenAI 호출 5건에서 관측한 요청·응답 전달은 모두 일치했습니다. AI 출력은 정해진 내용 기준에서 4건 충족·싱글 1건 불일치였고, 자유 서술 전체의 사실성과 운영 환경 신뢰성은 추가 검증이 필요합니다.

측정 및 근거

모델: gpt-4.1-mini-2025-04-14 · temperature 0 · 자동 재시도 없음

토큰 합계: 28,121개 (입력 24,454 / 출력 3,667) · 청구 금액 미산정

실제 로컬 A2A·인증·임시 SQLite·Task/Artifact 조회와 실제 API 호출을 사용했습니다.

원자료는 이 개정 전 Git 커밋 `b1a2508`의 동일 폴더 `report.json`에 있습니다. 개정본은 PDF만 배포하며, 새 API 호출은 수행하지 않았습니다.

원자료 SHA-256: `4c2dc3b29b81748b408c87f6840f2ed096f927fe856966c73a3e4299f0b5d5ad`